

Тезисы.

Тезис 1 (про 2 претензию к сильному ИИ)

Джон Сёрл доказывает, что могут существовать системы наподобие его китайской комнаты не понимающие языка. А вот факт, что таких систем нет - не доказывает. Наоборот, человек и есть та самая система опровергающая это.

Джон Сёрл пишет: *"Случай с английским языком, когда я понимаю, отличается от случая с китайским языком, когда я не понимаю, просто тем, что в первом случае я проделываю больше манипуляций с формальными символами. Я не показал, что это утверждение ложно, но в данном примере оно определенно должно казаться неправдоподобным."*

Наш тезис: Понимание возникает не через механическое следование синтаксическим правилам, а через формирование ассоциативных связей, опыта и семантики, что можно обнаружить как в человеческом мышлении, так и в "мышлении" ИИ.

Доказательство:

1) Мы начинаем изучение языка с изучения формальных правил. Постепенно они превращаются в интуитивное понятие, где ассоциации и контекст являются главными. Пример: Человек, изучающий иностранный язык, сначала следует грамматическим шаблонам, но со временем начинает «думать» на этом языке, связывая слова с их значениями (например, «любовь» - «love» не набор символов, а эмоция).

2) Понимание включает коррекцию ассоциаций на основе опыта, что выходит за рамки формальной логики.

На своём примере: впервые услышав слово "отрадный" (больше 5 лет назад) я подумал, что оно значит что-то типа "отвратный", но как оказалось это вообще антоним! Я довольно долго "переучивался", чтобы ассоциация встала нормальной. Получается, я стал понимать слово "отрадный", когда "обучился".

Тезис 2 (про эмерджентность)

Аргумент: Сёрл игнорирует возможность того, что понимание и сознание могут быть эмерджентными свойствами сложных систем. Даже если отдельные компоненты системы (например, нейроны или алгоритмы) не обладают пониманием, система в целом может обладать им.

Сёрл вообще странно рассматривает семантику системы («человек в комнате» vs «вся комната»): он пишет - давайте разделим (про китайскую комнату) 2 подсистемы - опа, теперь одна имеет семантику, а 2 нет

Но ведь при разделении он сломал ту самую общность системы

Пример: давайте отделим часть мозга, которая отвечает за речь - всё мы теперь мыслим другим, а речь не понимаем

Пример: Вода обладает свойствами (например, текучестью), которых нет у отдельных молекул H_2O . Аналогично, сознание может быть свойством, возникающим на уровне всей системы, а не её частей.

Тезис 3 (Критика робастности)

Сёрл отвергает этот аргумент, что можно дать роботу инструменты для взаимодействия с внешним миром, утверждая, что даже если робот взаимодействует с ним, он всё равно оперирует только формальными символами, не понимая их смысла.

Наша позиция: мы не можем сказать, что он не понимает смысла ровно с такой же уверенностью, как можем сказать, что любой человек не имеет понимания.

Сейчас в ИИ огромное количество ограничений только для того, чтобы они нам помогали. Но что если сделать "сырую" ИИ с инструментами для познания и хранения информации и отправить её по миру учиться? Точно можно сказать, что она выйдет крайне не похожей на человека, но у неё будет свое какое-то представление.

Тезис 4 (про "биологический шовинизм")

Сёрл утверждает, что он понимает, в отличие от машины *"потому, что я являюсь организмом определённого рода с определённой биологической (то есть химической и физической) структурой, и эта структура, при определённых условиях, каузально способна продуцировать восприятие, действие, понимание, обучение и другие интенциональные феномены."* Он настаивает, что без таких процессов существование понимания невозможно: он не опровергает, что возможно получить например "марсиан", созданных из других веществ. Но он заявляет, что биологические процессы всё же необходимы.

Наш тезис: ИИ должен копировать именно функциональную структуру мышления.

Например, если создать искусственный нейрон с теми же свойствами, что и биологический, его интеграция в систему приведет к тем же эффектам.

Вопросы оппонентам.

Как вы поняли позицию автора относительно "понимания" и условий существования "семантики"?

Если бы мы создали точную цифровую копию человеческого мозга, работающую на кремниевых чипах, отрицали бы вы её сознание только из-за отсутствия "биологической основы"?

Разве "китайская комната" в мысленном эксперименте не модель?